
VERİ BİLİMİ

DÖNEM PROJESİ RAPORU

E-Ticaret & Müşteri Davranışı Analizi

Veri Seti: UCI Online Retail Dataset (Kaggle: carrie1/ecommerce-data)

Ders : Veri Bilimi

Dönem : 2025-2026 Bahar Dönemi | İstanbul Üniversitesi-Cerrahpaşa

Teslim Tarihi: 3 Temmuz 2026

Hava İpek Karagöz
1306240041

1. Problem Tanımı ve Veri Seti

1.1 Problem Tanımı

Bu çalışmada, İngiltere merkezli bir online hediyeçilik mağazasının 2010-2011 yıllarını kapsayan işlem verisi analiz edilmiştir. Temel amaç, ham satış verisinden anlamlı iş içgörülerini çıkarmak ve veri bilimi iş akışını uçtan uca uygulamaktır.

Analiz beş araştırma sorusu etrafında şekillenmiştir: iadelerin gelire etkisi, mevsimsel örüntüler, müşteri segmentasyonu (RFM + K-Means), Pareto dağılımı ve sadakat profili. Bu sorular, gerçek bir e-ticaret yöneticisinin cevaplamak isteyeceği kritik iş sorularını yansıtmaktadır.

1.2 Veri Seti

Online Retail Dataset, UCI Machine Learning Repository üzerinden kamuya açık olarak sunulmaktadır. Britanyalı bir perakendecinin gerçek B2B ve B2C işlem kayıtlarını içermektedir. Kaggle'da [carrie1/ecommerce-data](#) adıyla erişilebilir.

Özellik	Değer
Kaynak	UCI Machine Learning Repository — Online Retail Dataset
Lisans	CC BY 4.0 (açık erişim, atıf gerektirir)
Dönem	01.12.2010 – 09.12.2011 (yaklaşık 1 yıl)
Ham Boyut	541.909 satır × 8 sütun
Sütunlar	InvoiceNo, StockCode, Description, Quantity, InvoiceDate, UnitPrice, CustomerID, Country
Benzersiz Müşteri ve Benzersiz Ürün	4.338 (temizleme sonrası) ve 3.665
İş Modeli	Online hediyeçilik; müşteri tabanı büyük ölçüde toptan alıcılar (B2B)

2. Yöntem

2.1 Geliştirme Yaklaşımı: Vibe Coding & Çok Modelli Doğrulama

Projeyi geliştirirken "vibe coding" yaklaşımını benimsedim; yani her adımda kodu satır satır elle yazmak yerine yapay zeka asistanlarını aktif bir geliştirme ortağı olarak kullandım. Ancak tek bir modele güvenmek yerine üç farklı büyük dil modelini çapraz doğrulama amacıyla paralel biçimde devreye aldım:

- Claude (Anthropic):** Özellikle veri temizleme pipeline'ı, RFM hesaplamaları ve K-Means seçim mantığını (elbow + silhouette kombinasyonu) tasarlarken tercih ettim. Her kod bloğunun altına açıklayıcı yorum satırları eklemem konusunda da Claude yönlendirmesi oldukça verimli oldu.
- Gemini (Google):** EDA görselleştirme renk seçimleri, seaborn/matplotlib konfigürasyonları ve ülke bazlı satış grafiğindeki UK ayrımı gibi konularda Gemini'nin önerilerini test ettim. Özellikle heatmap pivot yapısının doğrulanmasında farklı bir bakış açısı sundu.

- **ChatGPT (OpenAI):** Araştırma sorularını netleştirme aşamasında ChatGPT ile beyin fırtınası yaptım. Pareto eğrisi yorumlama ve segment isimlendirme konularında ChatGPT'nin iş analitiği perspektifinden ürettiği öneriler bulguların yazımını zenginleştirdi.

Üç modelin ürettiği her çıktı Jupyter Notebook üzerinde bizzat çalıştırılıp doğrulandı; anlaşılmayan veya çelişen sonuçlar manuel incelemeden geçirildi. Bu süreç hem hata riskini azalttı hem de modeller arası farklı açıklamaları karşılaştırma fırsatı sundu.

2.2 Veri Temizleme

Ham verinin kalitesini korumak için önce orijinal DataFrame'in bir kopyası üzerinde çalıştım. Temizleme aşamaları sırasıyla şöyle ilerlemekte:

İşlem Adımı	Etki	Kalan Kayıt
Ham Veri	—	541.909 satır
İadeler ayrıldı (C* faturalar)	-9.288 işlem	532.621 satır
UnitPrice ≤ 0 çıkarıldı	-0 satır	532.621 satır
CustomerID eksikler çıkarıldı	-132.220 satır	400.401 satır
Tekrarlayan satırlar çıkarıldı	-5.192 satır	392.692 satır
Temizlenmiş Veri	~%27 azalma	392.692 satır

InvoiceDate sütunu string'den datetime64 tipine dönüştürüldü; bu dönüşüm sayesinde aylık gruplama, çeyreklik analiz ve saat/gün türetimi mümkün hale geldi. Ayrıca TotalPrice = Quantity × UnitPrice formülüyle türetilmiş bir gelir sütunu oluşturuldu. CustomerID eksikliğinin ~%25 oranında olması önemli bir sınırlama olmakla birlikte, kalan veri müşteri analizi için yeterli örneklem büyüklüğüne sahiptir.

2.3 Keşifsel Veri Analizi (EDA)

EDA aşamasında 5 farklı görselleştirme tipi kullanıldı: aylık satış trendi (çizgi grafik), en çok satan ürünler (yatay bar), saatlik dağılım (bar), gün × saat yoğunluğu (heatmap) ve ülke bazlı gelir (yatay bar). Bu görseller AS1–AS2 araştırma sorularına doğrudan zemin hazırladı.

2.4 Modelleme: RFM + K-Means Kümeleme

Müşteri segmentasyonu için iki aşamalı bir yaklaşım izlendi. İlk aşamada her müşteri için üç RFM metriği hesaplandı:

- Recency: Referans tarihinden (veri setindeki son tarih + 1 gün) müşterinin son alışverişine kadar geçen gün sayısı.
- Frequency: Müşteriye ait tekil fatura sayısı (nunique ile hesaplandı).
- Monetary: Müşterinin toplam TotalPrice toplamı (£).

İkinci aşamada K-Means algoritması uygulandı. Uzaklık tabanlı çalışan K-Means'in farklı ölçekteki değerlerden olumsuz etkilenmemesi için StandardScaler ile normalleştirme yapıldı. K seçimi iki yöntemle doğrulandı: Elbow Plot (K=3-4 aralığında kırılma) ve Silhouette Score karşılaştırması (K=4 için 0.6162, K=5 için 0.6165). K=5'teki marjinal artış ve yorumlanabilirlik açısından K=4 tercih edildi.

3. Bulgular

3.1 Keşifsel Veri Analizi (EDA)

Görsel	Tür	Temel Bulgu
Aylık Satış Trendi	Çizgi Grafik	Kasım 2011 zirvesi — Noel öncesi alışveriş dalgası
En Çok Satan 10 Ürün	Yatay Bar	İlk 3 ürün hediyeçilik kategorisinde (Paper Craft, Ceramic Jar...)
Saatlik İşlem Dağılımı	Bar Grafik	10:00–15:00 en yoğun dönem; zirve saat 12:00 (3.130 fatura)
Gün × Saat Yoğunluğu	Isı Haritası	Pazar ve Cumartesi neredeyse hiç işlem yok (B2B profili)
Ülke Bazlı Satış (UK hariç)	Yatay Bar	İngiltere'yi Hollanda, EIRE ve Almanya izliyor

EDA'dan öne çıkan en kritik bulgu, işletmenin açıkça B2B ağırlıklı bir yapıya sahip olduğudur. Heatmap'te Cumartesi ve Pazar günleri neredeyse tamamen boşken hafta içi 10:00-15:00 bloğu kırmızıyla dolmaktadır. İngiltere'nin toplam gelirdeki %82'lik payı, uluslararası pazarın henüz büyüme potansiyeli taşıdığına işaret etmektedir.

3.2 Araştırma Soruları ve Bulgular

Araştırma Sorusu	Temel Bulgu
AS1 — İadelerin gelire etkisi	İade/Satış oranı %10.09 (£896.812). En yüksek iade AMAZON FEE ve PAPER CRAFT.
AS2 — Mevsimsellik ve saat örüntüsü	Son çeyrekte belirgin artış. Hafta içi gelir haftasonunun ~10 katı. Tipik B2B saatleri.
AS3 — RFM segmentasyonu	4 anlamlı segment bulundu; Silhouette: 0.6162. 13 VIP müşteri tek başına gelirin büyük bölümünü oluşturuyor.
AS4 — Pareto analizi	Müşterilerin %26'sı toplam gelirin %80'ini üretiyor. Klasik 80-20 kuralını doğruluyor.
AS5 — Müşteri sadakati	Tekrar eden müşteri %65.6. Tekrar edenlerin ort. harcaması £2.908 vs tek seferlikte £411.

3.3 Müşteri Segmentleri

Cluster	Segment Adı	Recency	Frequency	Monetary	Müşteri Sayısı
2	VIP / Şampiyon	7 gün	82 fatura	£127.187	13
3	Sadık Müşteriler	15 gün	22 fatura	£12.690	204
0	Aktif / Potansiyel	43 gün	3 fatura	£1.354	3.054

1	Kaybedilen / Uyuyan	248 gün	1 fatura	£479	1.067
---	---------------------	---------	----------	------	-------

K-Means sonucunda ortaya çıkan dört segment, birbiriyle tutarlı bir iş hikayesi anlatmaktadır. Cluster 2 (VIP), yalnızca 13 müşteriden oluşmakla birlikte ortalama £127.187'lik harcamasıyla toptan alıcı profiline kesin olarak işaret etmektedir. Bu grubu Pareto analizi de desteklemektedir: müşterilerin %26'sı gelirin %80'ini oluşturmaktadır.

Cluster 0 (Aktif/Potansiyel) en kalabalık gruptur (3.054 müşteri) ve sıklıkları düşük olmasına karşın para harcıyorlar — bu da onları doğru kampanyalarla Cluster 3'e dönüştürmek için en değerli büyüme rezervi haline getiriyor.

4. Sınırlamalar

- CustomerID eksikliği nedeniyle işlemlerin ~%25'i müşteri analizinin dışında kaldı. Kayıp verinin rastgele olduğu varsayılmıştır, ancak sistematik bir kayıp örüntüsü olasılığı göz ardı edilemez.
- Veri seti tek bir yılı kapsıyor; uzun vadeli trend yorumları veya yıllar arası mevsimsellik karşılaştırması yapmak mümkün değildir.
- Ürün kategorisi bilgisi olmadığından kategori bazlı analiz (örn. hangi ürün grubunda iade daha yüksek?) yapılamadı.
- K-Means küre şeklinde kümeler varsayar. Farklı şekle sahip segmentler için DBSCAN veya GMM daha uygun olabilirdi; ancak bu proje kapsamında K-Means yeterince savunulabilir bir tercih olarak değerlendirilmiştir.
- İade listesindeki AMAZON FEE ve Manual gibi kalemler gerçek ürün iadeleri değildir; bu durum iade oranı yorumunu sınırlandırmaktadır.

5. Öğrenilenler

5.1 Teknik Öğrenilenler

- Gerçek veri temizlenmiş gelmez. Temizleme adımı toplam geliştirme süresinin yaklaşık yarısını aldı; bu deneyim veri mühendisliğindeki "veri hazırlama = işin %80'i" sözünü somutlaştırdı diyebilirim.
- RFM, iş yorumu güçlü ve hesaplanması nispeten basit bir özellik mühendisliği örneğidir. Karmaşık modeller kurmadan önce bu tür domain-driven özelliklerin türetilmesi hem model performansını artırır hem de yorumlanabilirliği kolaylaştırır.
- Silhouette score, elbow yöntemini tamamlayan kritik bir araçtır. Elbow K=3-4 önerisini silhouette analizi K=4 ile netleştirdi; tek metriğe güvenmek yanıltıcı olabilirdi.
- StandardScaler, K-Means öncesinde zorunludur. Ölçeklendirme öncesinde £127.000 Monetary değeri tüm kümeleme sonuçlarını bozuyordu; normalizasyon bu etkiyi tamamen ortadan kaldırdı.

5.2 Süreç Öğrenilenleri

- Çok modelli AI doğrulama yaklaşımı (Claude + Gemini + ChatGPT) tek bir asistana kıyasla çok daha güvenilir sonuçlar üretti. Her modelin güçlü olduğu alan farklıdır; Claude kod açıklamasında, Gemini görsel konfigürasyonunda, ChatGPT iş yorumunda öne çıktı.
- AI'nin ürettiği kodu körü körüne çalıştırmak değil, her satırın ne yaptığını anlayarak ilerlemek, hata ayıklama süresini ciddi ölçüde kısalttı. Özellikle groupby + agg kombinasyonlarında ve silhouette döngüsünde bu yaklaşım belirleyici oldu.

- Araştırma sorularını önceden tanımlamak analizi odaklı tuttu. Amaçsız keşifsel analiz yerine hipotez odaklı bir yol izlemek hem zaman verimliliği sağladı hem de bulgular bölümünün tutarlı bir anlatı oluşturmaya katkıda bulundu.
- Prompt günlüğü tutmak geliştirme sürecinin dokümanı haline geldi. Hangi aşamada hangi modelden ne istendiğini kayıt altına almak, hem hata tespit etmeyi hem de projeyi tekrar etmeyi kolaylaştırdı.

6. Geliştirme Süreci

■ GÜN 1 – Analiz ve Geliştirme

Kaggle üzerinden dataseti indirerek projeye başladım. İlk adımda veri okuma ve keşif aşamasını tamamladım; veriyi `pd.read_csv` ile yüklemeye çalıştığımda encoding hatası aldım. Dosyada Türkçe/Fransızca gibi özel karakterler bulunduğundan ISO-8859-1 parametresinin neden zorunlu olduğunu araştırdım ve bu konuyu AI asistanlarıyla tartışarak pekiştirdim. Veri temizleme pipeline'ını oluşturdum: iade ayrımı, UnitPrice filtresi, CustomerID eksikleri ve duplicate temizliği. Ardından EDA aşamasına geçerek aylık trend, ürün, saat, gün×saat ısı haritası ve ülke görsellerini oluşturdum. Beş araştırma sorusu tanımlayarak her birini analiz ettim (iade oranı, mevsimsellik, RFM segmentasyonu, Pareto analizi, sadakat dağılımı). Günü K-Means modellemesiyle kapattım: elbow plot, silhouette kontrolü ve K=4 seçimini tamamladım.

■ Gün 2 – Dokümantasyon ve Çapraz Doğrulamalar

Teslim edilecek dosyaları hazırladım: geliştirme boyunca kullandığım önemli promptları kronolojik sırayla kaydettiğim `prompt_log.md`'yi, projenin çalıştırma talimatlarını ve kütüphane listesini içeren `README.md`'yi ve elimdeki raporu yazdım. Ardından üç farklı AI modeli arasında çapraz doğrulama yaptım: aynı analiz sonuçlarını Claude, Gemini ve ChatGPT'ye bağımsız olarak yorumlattım ve çıktıları karşılaştırdım. Bu süreç hem potansiyel hataları ortaya çıkardı hem de segment isimlendirme ve iş yorumları için daha zengin bir bakış açısı sağladı.

■ Gün 3 – GitHub ve Son Kontroller

Projeyi GitHub repository'sine yükledim. Notebook'un baştan sona hatasız çalıştığını doğruladım, tüm dosyaların (notebook, rapor, prompt günlüğü, README) repository'de eksiksiz bulunduğunu kontrol ettim ve linki teslim için hazırladım.

7. Kaynakça

Chen, D. (2015). Online Retail Dataset. UCI Machine Learning Repository. <https://archive.ics.uci.edu/dataset/352/online+retail>

Kaggle Dataset: <https://www.kaggle.com/datasets/carrie1/ecommerce-data> — Lisans: CC BY 4.0

scikit-learn: Pedregosa et al. (2011). Scikit-learn: Machine Learning in Python. JMLR 12, 2825–2830.

pandas: McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference.

Hazırlayan: Hava İpek Karagöz

Öğrenci No: 1306240041

Bölüm: Bilgisayar Mühendisliği 2. Sınıf